Tarea 2: Modelos Lineales Generalizados (MLG)

Demostraciones Teóricas, Cuasi-Verosimilitud, Regresión Simplex y Regresión Beta

Estudiante: Julian Hernandez

ctober 19, 2026

1 Demostración Formal en Modelos Lineales Generalizados

1.1 Planteamiento

Sea un Modelo Lineal Generalizado con media condicional $\mu_i = \mathbb{E}(Y_i) > 0$, función de varianza $V(\mu_i)$ y predictor lineal $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta} = \sum_{j=1}^{p} x_{ij}\beta_j$, con función de enlace:

$$\eta_i = g(\mu_i) = \begin{cases} \mu_i^\lambda, & \text{si } \lambda \neq 0, \\ \log(\mu_i), & \text{si } \lambda = 0. \end{cases} \tag{1}$$

Para $\lambda = 0$, la matriz de diseño $\mathbf{X}$ contiene la primera columna con unos ($x_{i1} = 1$). Se requiere demostrar la relación de ortogonalidad de puntuación:

$$\sum_{i=1}^{n} \frac{\hat{\mu}_i}{\hat{V}_i}(y_i - \hat{\mu}_i) = 0. \tag{2}$$

1.2 Deducción

Las ecuaciones de verosimilitud (score equations) respecto al vector $\boldsymbol{\beta}$ están dadas por:

$$U_j(\boldsymbol{\beta}) = \frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^{n} \frac{y_i - \mu_i}{\phi V(\mu_i)} \left(\frac{\partial \mu_i}{\partial \eta_i}\right) x_{ij} = 0, \quad \forall j = 1, \ldots, p. \tag{3}$$

Como $\frac{\partial \mu_i}{\partial \eta_i} = \frac{1}{g'(\mu_i)}$, evaluando en los estimadores de máxima verosimilitud $\hat{\boldsymbol{\beta}}$ (donde $\phi > 0$ se cancela):

$$\sum_{i=1}^{n} \frac{y_i - \hat{\mu}_i}{V(\hat{\mu}_i)} \frac{1}{g'(\hat{\mu}_i)} x_{ij} = 0, \quad j = 1, \ldots, p. \tag{4}$$

1.2.1 Caso 1: $\lambda \neq 0$

La función de enlace es $\eta_i = \mu_i^\lambda$. Su derivada es $g'(\mu_i) = \lambda \mu_i^{\lambda-1}$, luego:

$$\frac{1}{g'(\hat{\mu}_i)} = \frac{1}{\lambda \hat{\mu}_i^{\lambda-1}}. \tag{5}$$

Multiplicando cada ecuación (4) por $\hat{\beta}_j$ y sumando sobre $j = 1, \ldots, p$:

$$\sum_{i=1}^{n} \frac{y_i - \hat{\mu}_i}{V(\hat{\mu}_i)\lambda \hat{\mu}_i^{\lambda-1}} \left(\sum_{j=1}^{p} x_{ij}\hat{\beta}_j\right) = 0. \tag{6}$$

Dado que $\sum_{j=1}^{p} x_{ij}\hat{\beta}_j = \hat{\eta}_i = \hat{\mu}_i^\lambda$, sustituimos y simplificamos:

$$\sum_{i=1}^{n} \frac{y_i - \hat{\mu}_i}{V(\hat{\mu}_i)} \frac{\hat{\mu}_i^\lambda}{\lambda \hat{\mu}_i^{\lambda-1}} = \frac{1}{\lambda} \sum_{i=1}^{n} \frac{\hat{\mu}_i}{\hat{V}_i}(y_i - \hat{\mu}_i) = 0. \tag{7}$$

Como $\lambda \neq 0$, multiplicamos por λ y se concluye:

$$\sum_{i=1}^{n} \frac{\hat{\mu}_i}{\hat{V}_i}(y_i - \hat{\mu}_i) = 0. \quad \blacksquare \tag{8}$$

1.2.2 Caso 2: $\lambda = 0$

La función de enlace es $\eta_i = \log(\mu_i)$, por lo que $g'(\mu_i) = 1/\mu_i \implies \frac{1}{g'(\hat{\mu}_i)} = \hat{\mu}_i$. Como la matriz modelo posee una columna de unos ($x_{i1} = 1$), evaluando la ecuación (4) para $j = 1$:

$$\sum_{i=1}^{n} \frac{y_i - \hat{\mu}_i}{\hat{V}_i}(\hat{\mu}_i)(1) = \sum_{i=1}^{n} \frac{\hat{\mu}_i}{\hat{V}_i}(y_i - \hat{\mu}_i) = 0. \quad \blacksquare \tag{9}$$

2 Incidencia de Mancha en Hojas de Cebada (`cebada.dat`)

2.1 Análisis Descriptivo

El experimento comprende 90 parcelas cruzando 9 lugares geográficos y 10 variedades de cebada. Se evidencia un gradiente de infección creciente hacia los lugares 8 y 9, y susceptibilidad diferenciada según variedad (variedades 1 a 4 muy resistentes; 8 a 10 altamente susceptibles).

2.2 Modelos de Cuasi-Verosimilitud

Se formula $\mathbb{E}(Y_{ij}) = \pi_{ij}$, $\text{Var}(Y_{ij}) = \sigma^2 V(\pi_{ij})$ y enlace logit:

$$\log\left(\frac{\pi_{ij}}{1 - \pi_{ij}}\right) = \alpha + \beta_i + \gamma_j. \tag{10}$$

- Para $V_1(\pi) = \pi(1 - \pi)$: $\hat{\sigma}^2 = 0.0888$, observándose una marcada dispersión heterocedástica en los extremos.
- Para $V_2(\pi) = \pi^2(1 - \pi)^2$: $\hat{\sigma}^2 = 0.3902$, logrando estabilizar la varianza residual en todo el rango predicho.

2.3 Imposibilidad de Ajustar Regresión Simplex a `cebada.dat`

Respuesta: No es posible de forma directa. **Argumentación:** La densidad simplex $S^-(\mu, \sigma^2)$ está definida en el soporte abierto $y \in (0, 1)$ con devianza unitaria:

$$d(y, \mu) = \frac{(y - \mu)^2}{y(1 - y)\mu^2(1 - \mu)^2}. \tag{11}$$

En `cebada.dat` existen 4 observaciones idénticamente nulas ($y = 0.0000$). Cuando $y = 0$, el término $[y(1 - y)]^{-3/2}$ produce una división entre cero y $d(0, \mu) \to \infty$, provocando que la verosimilitud no esté definida.

3 Análisis de Grasa Corporal (`bodyfat.txt`)

3.1 Análisis Exploratorio

La proporción muestral $Y_i \in (0, 1)$ exhibe media 0.1894 y correlación positiva con la edad ($r = 0.2915$, $p < 0.001$).

3.2 Comparación: Regresión Simplex vs Beta

Modelo	$\hat{\beta}_0$ (EE)	$\hat{\beta}_1$ (EE)	Dispersión	AIC / BIC
Simplex	-2.0132 (0.1243)	$+0.0121$ (0.0028)	$\hat{\sigma}^2 = 2.3020$	-559.49 / -548.91
Beta	-1.9881 (0.2524)	$+0.0118$ (0.0053)	$\hat{\phi} = 25.2627$	$\mathbf{-593.23}$ / $\mathbf{-582.66}$

Table 1: Resultados inferenciales y comparación de criterios.

Conclusión: Aunque ambas curvas ajustadas capturan con precisión el incremento de grasa corporal con la edad ($\approx 1.2\%$ anual), el **Modelo Beta** es marcadamente superior ($\Delta\text{AIC} = 33.74$) y sus residuales cuantílicos siguen fielmente la normalidad teórica.